

Control 4: Selección de número de agrupamientos con K-Medias

Juan Muñoz, Vicente Rivera, Fernando Valdés

juan.munozveloso2023@alu.uct.cl, vriviera2023@alu.uct.cl, fvaldes2023@alu.uct.cl

Control 4, INFO1184, Semestre I-2026

Resumen

En este control se analiza el conjunto `wine.data` mediante k-means para comparar valores de k entre 2 y 15. En la Pregunta 1, la elección del número de grupos se realiza únicamente desde centroides y visualización, usando proyección PCA y evidencia numérica descriptiva de separación y fragmentación, sin aplicar métricas de calidad de clustering. En la Pregunta 2, se utiliza el método del codo con la suma de cuadrados intra-cluster (WSS). Los resultados muestran un quiebre principal al pasar de $k = 2$ a $k = 3$ y, desde $k = 4$, mejoras marginales asociadas a sobre-segmentación. Por ambas vías de análisis, se concluye que el valor más adecuado para este dataset es $k = 3$.

1. Introducción

El algoritmo k-means es una técnica de aprendizaje no supervisado que particiona un conjunto de observaciones en k grupos buscando alta similitud intra-cluster y separación inter-cluster. Su objetivo puede expresarse mediante la minimización de la suma de cuadrados intra-cluster:

$$WSS(k) = \sum_{j=1}^k \sum_{x \in C_j} \|x - \bar{x}_{C_j}\|^2, \quad (1)$$

donde $\bar{x}_{C_j}$ corresponde al centroide del cluster C_j .

En clases de semana 6 se revisó que la selección de k puede sustentarse tanto en criterio visual como en el método del codo (Lévano, 2026). El presente trabajo aplica ambos enfoques al set de vinos de UCI (178 observaciones, 13 variables continuas), estandarizando variables para evitar sesgo por escala (Aeberhard et al., 1991).

2. Desarrollo

2.1. Preparación de datos y configuración experimental

Se cargó `wine.data`, separando la etiqueta de clase original y usando solo variables numéricas para el agrupamiento. Luego se estandarizaron las 13 variables y se ejecutó k-medias para $k \in \{2, \dots, 15\}$ con `set.seed(101)`, `nstart=100` e `iter.max=200`. El script completo se presenta en el Anexo A.2.

2.2. Pregunta 1: Comparación por centroides y visualización

Siguiendo estrictamente el enunciado, esta pregunta se responde sin usar método del codo ni índices clásicos de calidad de clustering. La evaluación se realizó mediante: (i) visualización de grupos y centroides en PCA (Fig. 1), y (ii) análisis descriptivo de distancia mínima entre centroides y tamaño del clúster menor (Fig. 3 y Fig. 4).

k	Dist. mín. entre centroides	Clúster más pequeño	Lectura descriptiva
2	3.827	87	Partición gruesa
3	3.586	51	Tres grupos bien definidos
4	2.705	28	Subdivisión adicional
6	2.535	4	Fragmentación marcada
10	1.789	3	Sobre-segmentación
15	1.873	2	Micro-clusters inestables

Cuadro 1: Indicadores descriptivos basados en centroides para valores representativos de k .

La Tabla 1 y la Fig. 1 muestran que con $k = 3$ se obtiene una estructura interpretable y estable; para $k \geq 6$ aparecen grupos muy pequeños y cercana superposición de centroides, lo que dificulta la interpretación global.

Respuesta Pregunta 1: basándose solo en centroides y visualización, el número óptimo observado es $k = 3$.

2.3. Pregunta 2: Método del codo

Para esta pregunta se aplicó el método del codo sobre WSS total (ec. 1) para $k = 2, 15$.

k	WSS	Disminución porcentual respecto a $k - 1$
2	1649.44	—
3	1270.75	22.96 %
4	1168.61	8.04 %
5	1095.15	6.29 %
6	1032.80	5.69 %
7	975.92	5.51 %

Cuadro 2: Resumen del método del codo (extracto $k = 2$ a $k = 7$).

El mayor quiebre ocurre de $k = 2$ a $k = 3$ (22.96 % de reducción), y desde $k = 4$ las mejoras pasan a ser menores y decrecientes. La curva completa se observa en la Fig. 2.

Respuesta Pregunta 2: por método del codo, el número óptimo de agrupamientos es $k = 3$.

3. Reflexión

Este control permitió justificar la selección de k desde dos perspectivas complementarias: criterio geométrico (centroides y visualización) y criterio de compactación (WSS-codo). En este caso, ambos enfoques convergen en $k = 3$, reforzando la validez de la decisión.

De forma general, el trabajo también permite observar que la decisión sobre el número de clusters no debe basarse solo en reducir error interno, sino en conservar interpretabilidad de los grupos. Cuando k aumenta demasiado, aparecen micro-clusters que disminuyen la utilidad analítica del resultado y dificultan su traducción a decisiones de negocio.

Finalmente, la experiencia práctica en R consolida lo visto en clases: estandarizar variables, fijar semilla, comparar escenarios de k y respaldar conclusiones con evidencia numérica y visual son pasos necesarios para un análisis de conglomerados técnicamente sólido y comunicable en un informe técnico.

Referencias

- Aeberhard, S., Coomans, D., and de Vel, O. (1991). Wine recognition data set. UCI Machine Learning Repository. Dataset de vinos usado en el control.
- Lévano, M. (2026). Datos conglomerados. Diapositivas de clase, semana 6, Universidad Católica de Temuco. Material docente de la asignatura INFO1184.

Anexo

A.1 Figuras generadas




Figura 1: Visualización PCA con centroides para $k = 2, 3, 4, 7$.




Figura 2: Método del codo para $k = 2, \dots, 15$.




Figura 3: Diagnóstico 1: separación mínima entre centroides.




Figura 4: Diagnóstico 2: tamaño del clúster más pequeño.

A.2 Script R (procedimientos importantes)

```

1 # Control 4 - INF01184
2 set.seed(101)
3 wine <- read.csv("wine/wine.data", header = FALSE)
4 X <- scale(wine[, -1])
5
6 ks <- 2:15
7 wss <- sapply(ks, function(k) kmeans(X, centers = k, nstart = 100)$tot.withinss)
8
9 # Pregunta 1: diagnostico de centroides

```

```

10 diag_df <- data.frame(k = ks, min_centroid_dist = NA, min_cluster_size = NA)
11 for (i in seq_along(ks)) {
12   km <- kmeans(X, centers = ks[i], nstart = 100, iter.max = 200)
13   d <- as.matrix(dist(km$centers)); d[d == 0] <- NA
14   diag_df$min_centroid_dist[i] <- min(d, na.rm = TRUE)
15   diag_df$min_cluster_size[i] <- min(km$size)
16 }
17
18 # Pregunta 2: metodo del codo
19 plot(ks, wss, type = "b", pch = 19)
20 abline(v = 3, lty = 2, col = "red")

```

A.3 Bitácora de trabajo

Fecha	Actividad	Descripción
22/04/2026	Revisión de pauta y alcance	Se revisó el enunciado del control, la rúbrica general y el formato de entrega. Se definió el alcance del trabajo: responder la Pregunta 1 con evidencia basada en centroides/visualización y la Pregunta 2 con método del codo, sin mezclar criterios.
22/04/2026	Revisión de clases y criterios técnicos	Se estudiaron las diapositivas de semana 6 para alinear el procedimiento con la metodología vista en curso. Se confirmó uso de k-medias con datos estandarizados, comparación de $k = 2, 15$ y justificación del k óptimo con respaldo numérico y gráfico.
22/04/2026	Implementación en R y generación de evidencia	Se ejecutó el script <code>CC4_analisis.R</code> con semilla fija. Se calcularon métricas por cada k , se exportaron resultados a CSV y se generaron gráficos de PCA, codo y dos diagnósticos separados (distancia mínima entre centroides y tamaño del clúster más pequeño).
22/04/2026	Interpretación y redacción del informe	Se contrastaron resultados de las dos preguntas y se validó consistencia de la conclusión ($k = 3$). Luego se integraron tablas, figuras y referencias en $\text{\LaTeX}$, incorporando enlaces internos en anexos para facilitar la navegación y trazabilidad del análisis.

Cuadro 3: Bitácora de actividades del control.

A.4 Enlace a archivo .tex en Drive

<https://drive.google.com/drive/folders>