

Datos conglomerados

Prof. M. Lévano

Dpto. de Ingeniería Informática
Universidad Católica de Temuco

(semana 3–4)

Temario


- 1 Qué es Clustering?
- 2 Descripción del Problema
- 3 Representación de Objetos
- 4 Representación de Clusters
- 5 Similitudes
- 6 Clustering Partición
- 7 Clustering
- 8 Aglomerativo Jerárquicos: Aglomeración
- 9 Referencia

Qué es Clustering?

- Dado un conjunto de objetos, colocar los objetos en grupos basados en similitudes entre ellos.
- Utilizado para encontrar patrones en los datos.
- Inherentemente es un problema no definido claramente.

Descripción del Problema



- Clustering (Agrupamiento): Aprendizaje no supervisado.
- Dado un conjunto de objetos descritos por múltiples valores (atributos).
 - ▶ (1) Atribuir grupos (Clusters) a los objetos particionados objetivamente en grupos homogéneos de manera:
 - ★ Maximizar la similaridad de objetos dentro de un mismo Cluster.
 - ★ Minimizar la similaridad de objetos entre Clusters distintos.
 - ▶ (2) Atribuir una descripción para cada Cluster formado.



Representación de Objetos


- Cada objeto (dato) de entrada para el algoritmo es representado usualmente por un vector de **atribuos**.
- Tipos de atributos
 - ▶ Numérico (entero, real)
 - ▶ Categórico (booleano, conjunto de valores)
- Por ejemplo: una muestra de datos clinicos (objeto: Paciente)
 - ▶ edad (atributo numérico: entero)
 - ▶ peso (atributo numérico: real)
 - ▶ sexo (atributo categorico: masculino, femenino)
 - ▶ color de pelo (atributo categórico: blanco, negro, castaño, amarillo, marrón)
 - ▶ casado (atributo booleano: si, no)
- Se debe incluir un método para calcular la similaridad (o una distancia) entre los objetos.

Representación de Clusters



(c)


	1	2	3
a	0.4	0.1	0.5
b	0.1	0.8	0.1
c	0.3	0.3	0.4
...			



Similitudes

- Una distancia es un método más natural para los datos numéricos.
- Valores pequeños indican mayor similaridad.
- Métricas de distancia:
 - ▶ Euclidiana
 - ▶ Manhattan
 - ▶ Minkowski
 - ▶ Etc.
- No generaliza muy bien para los datos no numéricos. Ejemplo:Cuál es la distancia entre femenino y masculino ?. $\implies$ mapearlos ¿Cómo representarlos?. Preprocesamiento.

Similitudes



Similitudes

Dados dos vectores $\mathbf{x}_i, \mathbf{x}_j$ pertenecientes a $\mathbb{R}^k$, diremos que hemos establecido una distancia entre ellos si definimos una función d con las propiedades siguientes:

1. $d : \mathbb{R}^k \times \mathbb{R}^k \rightarrow \mathbb{R}^+$, es decir $d(\mathbf{x}_i, \mathbf{x}_j) \geq 0$;
2. $d(\mathbf{x}_i, \mathbf{x}_i) = 0 \quad \forall i$, la distancia entre un elemento y sí mismo es cero.
3. $d(\mathbf{x}_i, \mathbf{x}_j) = d(\mathbf{x}_j, \mathbf{x}_i)$, la distancia es simétrica
4. $d(\mathbf{x}_i, \mathbf{x}_j) \leq d(\mathbf{x}_i, \mathbf{x}_p) + d(\mathbf{x}_p, \mathbf{x}_j)$, la distancia verifica la propiedad triangular.

Estas propiedades generalizan la noción intuitiva de distancia euclídea entre dos puntos.

Clustering Partición

El objetivo es obtener una Partición de los objetos en Grupos o Clusters de tal forma que todos los objetos pertenezcan a alguno de los k-Clusters posibles y que por otra parte los Clusters sean disjuntos. Si denotamos $H = \{O_1, O_2, \dots, O_N\}$ al conjunto de N objetos, se trata de dividir H en k-Grupos o Clusters $C_1, C_2, \dots, C_k$ de tal forma que:

- $\bigcup_{j=1}^k C_j = H$
- $C_j \cap C_i = \emptyset$, para $i \neq j$

Uno de los problemas que uno se encuentra es establecer el K adecuado.

Existen algoritmos más sofisticados que son capaces de adaptar el valor k.

Clustering

Sea

$$X = \{x_1, x_2, \dots, x_n\}$$

un conjunto de muestras o datos. Definimos un agrupamiento $\mathfrak{R}$ con m grupos de X , como la partición de X en m conjuntos (grupos)

$R_1, R_2, \dots, R_m$ cumpliendo las tres condiciones siguientes:

- $R_i \neq \emptyset, i = 1, \dots, m$
- $\cup_{i=1}^m R_i = X$
- $R_i \cap R_j = \emptyset, i \neq j, i, j = 1, \dots, m$

Los vectores contenidos en un grupo R_i son similares entre sí y menos similares a los vectores de otro grupo.

Aglomerativo Jerárquicos: Aglomeración

Un agrupamiento R_1 conteniendo k grupos se dice que está **anidado** en el agrupamiento R_2 que contiene r ($r < k$) grupos, si cada grupo en R_1 es un subconjunto de un conjunto en R_2 y al menos un grupo de R_1 es un subconjunto propio de R_2 , en cuyo caso escribimos

$$R_1 \subset R_2$$

Aglomerativo Jerárquicos: Aglomeración

Ejemplo: El agrupamiento

$$R_1 = \{\{x_1, x_3\}, \{x_4\}, \{x_2, x_5\}\}$$

esta anidado en

$$R_2 = \{\{x_1, x_3, x_4\}, \{x_2, x_5\}\}$$

por otro lado R_1 no está anidado ni en

$$R_3 = \{\{x_1, x_4\}, \{x_3\}, \{x_2, x_5\}\}$$

ni en

$$R_4 = \{\{x_1, x_2, x_4\}, \{x_3, x_5\}\}$$

Además es claro que un agrupamiento no está anidado en si mismo.

Aglomerativo Jerárquicos: Aglomeración

El agrupamiento inicial R_0 consta de n grupos, cada uno conteniendo un elemento siempre de X .


En el primer paso se obtiene el agrupamiento R_1 que contiene $n-1$ conjuntos, de forma que $R_0 \subset R_1$, este procedimiento continúa hasta que se obtiene el agrupamiento final R_{n-1} , que contiene un único conjunto que es X .

Se produce una jerarquía de anidamiento

$$R_0 \subset R_1 \subset R_2 \subset, \dots, \subset R_{n-1}$$

Aglomerativo Jerárquicos: Aglomeración

Dendograma



Aglomerativo Jerárquicos: Aglomeración

Algoritmo

Sea $g(R_i, R_j)$ una función definida para todos los pares posibles de grupos en X . Esta función mide la proximidad entre R_i y R_j . Sea t el nivel actual de jerarquía.

1) Inicialización

Elegir $\mathfrak{R} = \{R_i = \{x_i\}, \quad i = 1, \dots, n\}$ como el agrupamiento inicial $t=0$.

2) Repetir hasta que todos los vectores pertenezcan al mismo grupo

$t = t-1$

Entre todos los pares posibles de grupos (R_r, R_s) en $\mathfrak{R}_{t-1}$ encontrar un (R_i, R_j) , tal que:

$$g(R_i, R_j) = \min_{s,r} g(R_r, R_s)$$

Si g mide No Similitud (mínima proximidad)

$$g(R_i, R_j) = \max_{s,r} g(R_r, R_s)$$

Si g mide Similitud (máxima proximidad)

Definir $R_q = R_i \cup R_j$ y generar el nuevo agrupamiento

$$\mathfrak{R}_t = (\mathfrak{R}_{t-1} - \{R_i, R_j\}) \cup \{R_q\}$$

Aglomerativo Jerárquicos: Aglomeración

Ejercicio 1:

Crear un dendograma para los siguientes 8 puntos en una dimensión.

$$\{-5.5, -4.1, -3.0, -2.6, 10.1, 11.9, 12.3, 13.6\}$$

Se define la similitud entre 2 clusters por $d_{min}(D_i, D_j)$, donde $d_{min}(D_i, D_j)$ esta dado como

$$d_{min}(D_i, D_j) = \min_{x \in D_i, x' \in D_j} \|x - x'\|$$

Aglomerativo Jerárquicos: Aglomeración

Ejercicio 2:

Crear un dendograma para los siguientes 8 puntos en una dimensión.

$$\{-5.5, -4.1, -3.0, -2.6, 10.1, 11.9, 12.3, 13.6\}$$

Se define la similitud entre 2 clusters como $20 - d_{\min}(D_i, D_j)$, donde $d_{\min}(D_i, D_j)$ esta dado como

$$d_{\min}(D_i, D_j) = \min_{x \in D_i, x' \in D_j} \|x - x'\|$$

Referencia

Duda R., Hart P. and Stork D., Pattern Classification. (2da. Edición), JOHN WILEY & SONS, INC, 2001.