Disertacion 3 | INFO1184

DBSCAN

Agrupamiento basado en densidad para detectar formas arbitrarias y ruido

Idea central

DBSCAN encuentra clusters sin fijar k y separa automaticamente los puntos atipicos.

Density-Based Spatial Clustering of Applications with Noise

Juan Munoz | Vicente Rivera | Fernando Valdes

Inteligencia de Negocios | Semestre I-2026

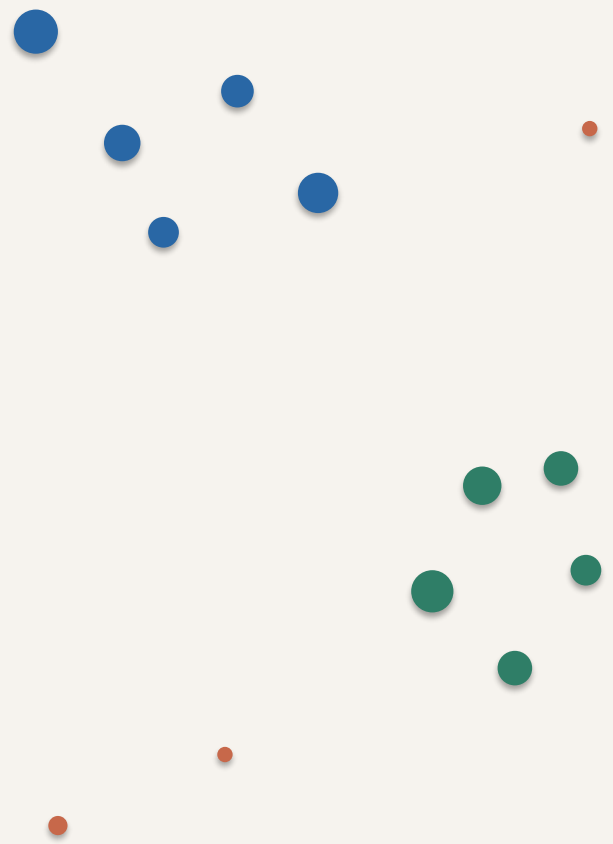

Panorama

Temario y propuesta

Estructura alineada con la pauta general de disertaciones

Temario

1. Contexto y problema del clustering
2. Funcionamiento de DBSCAN: eps, MinPts y expansion
3. Ejemplo demostrativo con datos sinteticos
4. Aplicaciones del metodo en casos reales
5. Ventajas, limitaciones y cierre

Proposicion

DBSCAN es especialmente util cuando el numero de grupos es desconocido y el ruido no puede ignorarse.

Gancho

En datos reales no siempre existen clusters redondos ni limpios; muchas veces hay formas irregulares y observaciones aisladas.

Problema

K-means necesita fijar k y suele asumir grupos compactos, por lo que puede forzar particiones poco naturales.

Respuesta de DBSCAN

Agrupa por densidad local: une puntos densos, reconoce bordes y deja fuera el ruido.

Valor analitico

Entrega clusters mas cercanos a la forma real de los datos cuando existen outliers o geometrias no esfericas.

Contexto

Que problema resuelve DBSCAN

Agrupar cuando la forma de los datos importa tanto como la distancia

Cuando un metodo tradicional falla

- El numero de clusters puede ser desconocido desde el inicio.
- La forma real puede ser curva, alargada o fragmentada.
- Los puntos atipicos distorsionan centroides y medias.
- En bases reales hay zonas densas y zonas poco pobladas.

Lectura clave

DBSCAN no pregunta primero cuantos grupos existen; primero identifica donde realmente hay densidad suficiente.

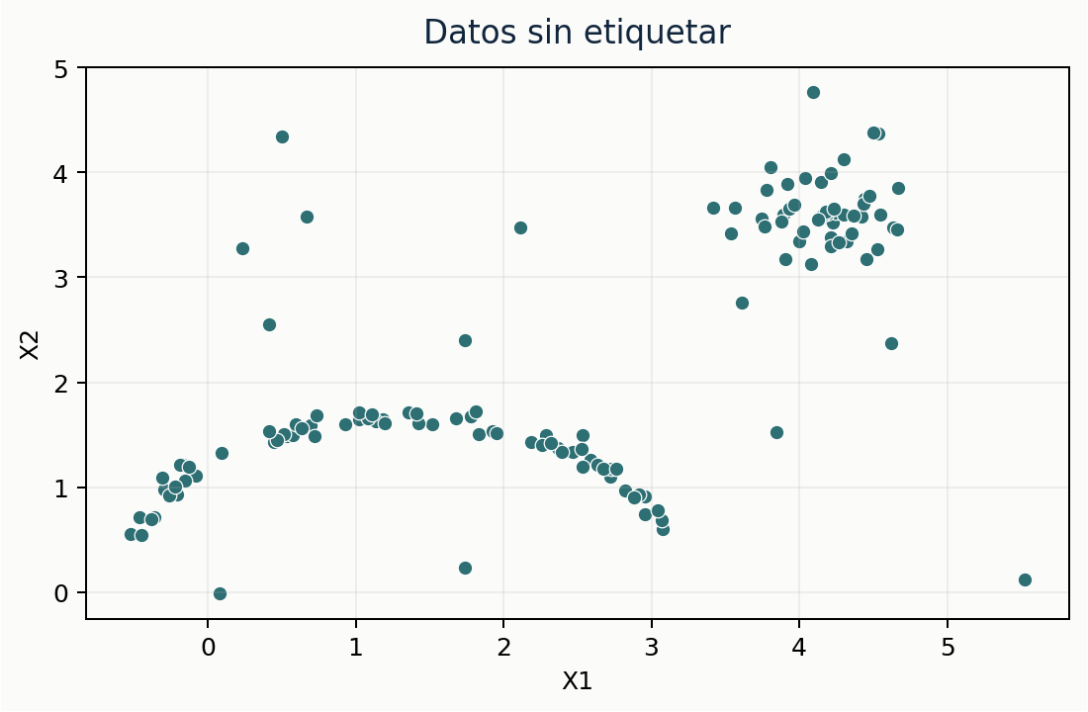

Fig. 1. Nube de datos con forma irregular y posibles outliers. Elaboracion propia.

Metodo

Como funciona DBSCAN

El cluster nace desde vecindades densas y se expande por conectividad

Conceptos base

eps — Radio que define la vecindad local de un punto.

MinPts — Minimo de puntos dentro de eps para considerar densidad suficiente.

Core — Punto cuyo vecindario contiene al menos MinPts.

Border — Punto cercano a un core, pero sin densidad propia suficiente.

Noise — Observacion que no queda conectada a ningun cluster denso.

$$N_eps(p) = \{ q \text{ in } D : dist(p, q) <= eps \} \quad (1)$$

Secuencia del algoritmo

01 Seleccionar un punto no visitado.

02 Contar su vecindad eps.

03 Si cumple MinPts, iniciar o expandir un cluster.

04 Si no cumple, marcarlo como ruido provisional.

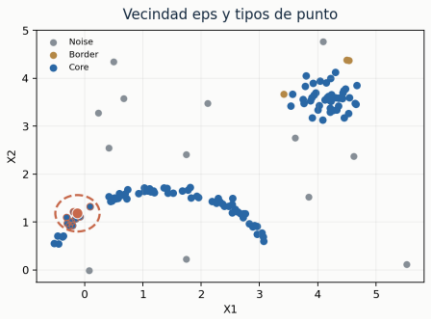

Fig. 2. Punto core, borde y ruido dentro de una vecindad eps. Elaboracion propia.

Ejemplo demostrativo

DBSCAN identifica dos zonas densas y deja fuera observaciones aisladas

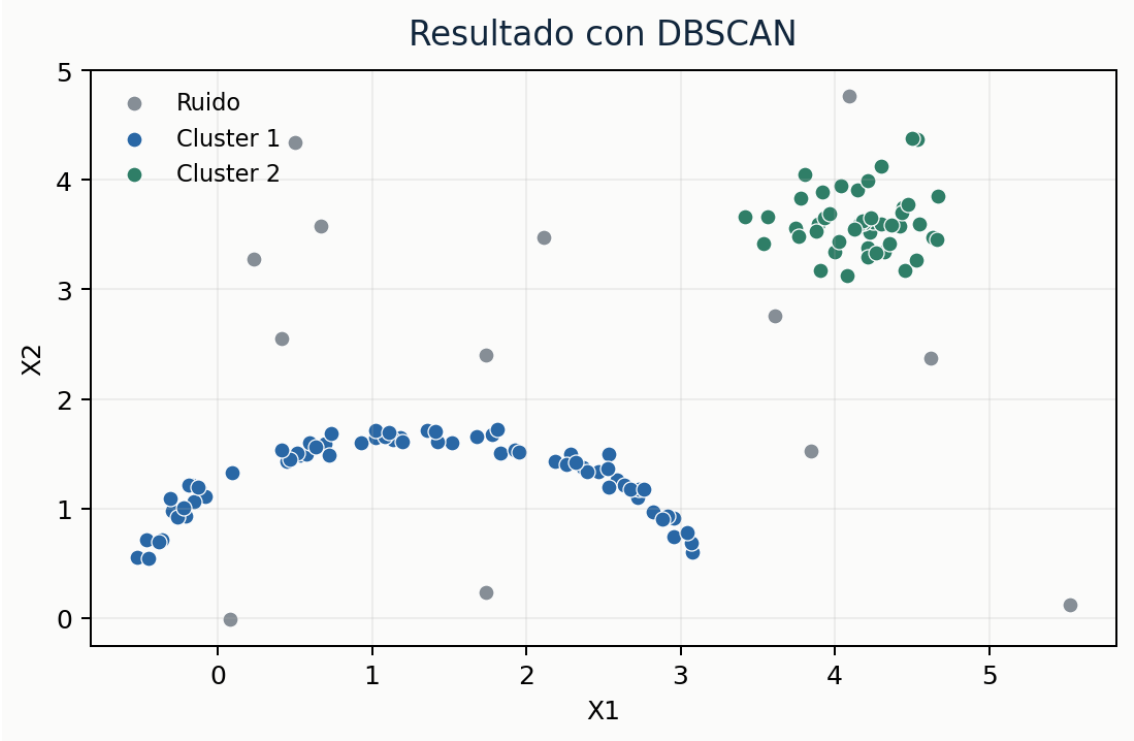

Fig. 3. Resultado de DBSCAN en un conjunto sintetico con forma curva, cluster compacto y ruido. Elaboracion propia.

Parametros usados

eps = 0.38 | MinPts = 5

Clusters detectados	2
Ruido detectado	13 puntos
Porcentaje ruido	9.8%

Interpretacion

La ventaja principal es que la forma curva se mantiene como un solo cluster sin obligarlo a ser esferico.

Donde se usa DBSCAN

El metodo es util cuando la densidad revela patrones mas valiosos que un centroide promedio

Analitica geoespacial

Caso de uso

Detecta zonas densas de accidentes, delitos, demanda de reparto o flujo de clientes.

Por que DBSCAN encaja

Funciona bien porque encuentra hotspots con forma irregular y separa eventos aislados.

Fraude y anomalias

Caso de uso

Separa patrones normales de transacciones y deja como ruido operaciones atipicas.

Por que DBSCAN encaja

Aporta valor porque el outlier no es un error: muchas veces es justamente el caso que interesa investigar.

Sensores y vision

Caso de uso

Agrupa puntos en nubes LiDAR, seguimiento de objetos o deteccion de estructuras en imagenes.

Por que DBSCAN encaja

Es adecuado porque reconoce objetos conectados por densidad aun cuando sus bordes no sean convexos.

Ventajas y limitaciones

Entender cuando usar DBSCAN es tan importante como saber ejecutarlo

Ventajas

- No exige definir k antes de comenzar.
- Encuentra clusters con forma arbitraria.
- Identifica ruido y outliers de forma explicita.
- Suele ser interpretable en datos geograficos o espaciales.

Limitaciones

- Elegir eps y MinPts puede ser sensible al contexto.
- Con densidades muy distintas puede fragmentar o fusionar clusters.
- La escala de las variables afecta directamente la distancia.
- En alta dimension la nocion de densidad pierde fuerza.

Buena practica: escalar variables, probar varios valores de eps y validar el resultado con conocimiento del dominio.

Cierre

Conclusiones

DBSCAN es fuerte cuando el ruido y la forma real de los datos no pueden simplificarse

Conclusion central

En dashboards de Inteligencia de Negocios, DBSCAN ayuda a revelar zonas densas, patrones y anomalias que no siempre son evidentes. Esto permite detectar oportunidades, anticipar riesgos y enfocar decisiones sobre los comportamientos que realmente importan.

Cuando conviene usarlo

Cuando existen outliers, clusters no esfericos o el numero de grupos aun no es conocido.

Que debemos cuidar

La seleccion de eps, el escalamiento de variables y la presencia de densidades muy desiguales.

Mensaje final

No todos los problemas de agrupamiento se resuelven con centroides; a veces la densidad es la verdadera estructura.

Integrantes: Juan Munoz, Vicente Rivera y Fernando Valdes

Bibliografia de apoyo

Referencias base para la definicion, discusion y ejemplo del metodo

- Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. Proceedings of KDD-96, 226-231.

- Han, J., Kamber, M., & Pei, J. (2012). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann.

- Schubert, E., Sander, J., Ester, M., Kriegel, H.-P., & Xu, X. (2017). DBSCAN revisited, revisited: Why and how you should still use DBSCAN. ACM Transactions on Database Systems, 42(3), 1-21.

- Presentacion elaborada segun la pauta general y rubrica de disertaciones del curso INFO1184, Semestre I-2026.

Las figuras incluidas en la presentacion son de elaboracion propia.