

Análisis Exploratorio, Clasificación y Segmentación de Pacientes en un Dataset de Enfermedad Cardíaca

Juan Muñoz, Vicente Rivera, Fernando Valdés

juan.munozveloso2023@alu.uct.cl, vriviera2023@alu.uct.cl, fvaldes2023@alu.uct.cl

Tarea 5, INFO1184, Semestre I-2026

Resumen

Este informe analiza un dataset de enfermedad cardíaca disponible en Kaggle, compuesto originalmente por 1.025 registros y 14 variables clínicas y demográficas. El objetivo fue identificar patrones asociados a la presencia de enfermedad cardíaca y evaluar modelos simples de clasificación para detectar posibles casos. El trabajo se desarrolló en Python siguiendo CRISP-DM: comprensión del problema, comprensión de datos, preparación, análisis, modelamiento y evaluación. Durante la limpieza se detectaron 723 duplicados exactos, por lo que el modelamiento se realizó con 302 registros únicos para reducir fuga de información. El análisis exploratorio sugirió asociación de **exang**, **cp**, **oldpeak**, **thalach** y **ca** con la variable objetivo. Se compararon regresión logística, KNN y árbol de decisión mediante split estratificado y validación cruzada; KNN con $k = 9$ obtuvo accuracy de 0,803 y F1-score de 0,832 en prueba. K-Means sugirió dos grupos, aunque con separación limitada. Los resultados son exploratorios, no constituyen diagnóstico médico y transforman datos clínicos en indicadores interpretables mediante una metodología reproducible.

Palabras clave: enfermedad cardíaca, clasificación, K-Means, CRISP-DM, Python, salud.

1. Introducción

La Inteligencia de Negocios busca convertir datos en información útil para comprender fenómenos, apoyar decisiones y priorizar acciones analíticas. En salud, esta lógica permite transformar registros clínicos en indicadores sobre patrones, perfiles de pacientes y posibles señales de riesgo. En enfermedades cardiovasculares, variables como edad, presión arterial, colesterol, frecuencia cardíaca máxima, angina inducida por ejercicio y resultados de pruebas clínicas pueden entregar evidencia exploratoria relevante. Sin embargo, un análisis académico no reemplaza la evaluación médica ni constituye diagnóstico.

El caso de estudio corresponde al *Heart Disease Dataset*, publicado en Kaggle por John Smith (Smith, 2026). La pregunta principal del grupo fue: ¿qué variables clínicas y demográficas se relacionan más con la presencia de enfermedad cardíaca en los pacientes del dataset? A partir de ella se plantearon preguntas secundarias sobre diferencias entre pacientes con y sin enfermedad, variables más asociadas, capacidad predictiva de modelos simples, identificación de perfiles mediante clustering y comportamiento comparado de clasificadores.

El objetivo general fue analizar el dataset mediante exploración, visualización, clasificación y agrupamiento. El desarrollo se implementó en Python con **pandas**, **scikit-learn**, **matplotlib** y **seaborn** (The pandas development team, 2020; Pedregosa et al., 2011; Hunter, 2007; Waskom, 2021), dejando un flujo reproducible y salidas exportadas como evidencia.

2. Fundamentos de Teoría

CRISP-DM organiza proyectos de minería de datos en comprensión del negocio, comprensión de datos, preparación, modelamiento, evaluación y despliegue (Chapman et al., 2000; Lévano, 2026a). En esta tarea se desarrollaron las primeras cinco fases, porque el alcance solicitado es analítico.

Para clasificación supervisada se usaron tres modelos vinculados al modelamiento predictivo y la estimación del error revisada en clases (Lévano, 2026d): regresión logística, K-Nearest Neighbors y árbol de decisión. La regresión logística estima la probabilidad de una clase binaria (Hosmer et al., 2013); KNN clasifica según vecinos cercanos y requiere escalamiento cuando las magnitudes difieren (James et al., 2021); el árbol separa datos mediante reglas sucesivas, con riesgo de sobreajuste si no se controla su profundidad (Breiman et al., 1984). El desempeño se evaluó con accuracy, precision, recall y F1-score:

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}, \quad \text{Precision} = \frac{VP}{VP + FP}, \quad \text{Recall} = \frac{VP}{VP + FN}. \quad (1)$$

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (2)$$

K-Means es un algoritmo no supervisado que particiona observaciones en k grupos minimizando distancias a centroides (MacQueen, 1967; Lévano, 2026b,c). Como trabaja con distancias euclidianas, se escalan las variables y se usaron solo

variables continuas; **target** quedó excluida de la entrada para no contaminar el análisis no supervisado. La selección de k se apoyó en inercia y silueta, entendiendo que valores bajos de silueta indican grupos solapados.

3. Desarrollo del Trabajo

3.1. Metodología paso a paso

La Tabla 1 resume las etapas ejecutadas y la Tabla 2 conecta cada pregunta de investigación con la técnica y evidencia usada para responderla.

Etapas	Actividad realizada
Comprensión del problema	Definición de preguntas sobre variables asociadas, predicción y perfiles de pacientes.
Comprensión de datos	Revisión de dimensiones, tipos, faltantes, duplicados y distribución de target .
Preparación y limpieza	Eliminación de duplicados exactos y construcción del dataset depurado.
Análisis exploratorio	Tablas descriptivas, boxplots, gráficos categóricos y matriz de correlación.
Modelamiento supervisado	Comparación de regresión logística, KNN y árbol de decisión.
Clustering	Aplicación de K-Means con variables continuas escaladas y perfilado posterior.
Evaluación e interpretación	Métricas, validación cruzada, matriz de confusión, silueta y discusión de limitaciones.

Cuadro 1: Etapas metodológicas aplicadas en el proyecto.

Pregunta de investigación	Técnica o método	Evidencia generada
Variables relacionadas con enfermedad cardíaca	Correlación, boxplots y gráficos categóricos	Matriz de correlación, ranking exploratorio y figuras por target .
Diferencias entre pacientes con y sin enfermedad	Estadística descriptiva por clase	Tabla de promedios y boxplots por target .
Predicción de enfermedad cardíaca	Regresión logística, KNN y árbol de decisión	Tabla de métricas, validación cruzada y matriz de confusión.
Perfiles de pacientes	K-Means, inercia, silueta y PCA	Gráfico de codo, proyección PCA y perfiles de clusters.

Cuadro 2: Relación entre preguntas, técnicas y evidencias.

3.2. Comprensión y preparación de datos

El dataset contiene 14 variables: edad, sexo, tipo de dolor torácico, presión arterial en reposo, colesterol, glucosa en ayunas, electrocardiograma en reposo, frecuencia cardíaca máxima, angina inducida por ejercicio, depresión ST, pendiente ST, vasos coloreados, resultado *thal* y **target**. La clase 0 indica ausencia de enfermedad cardíaca y la clase 1 indica presencia.

La revisión inicial identificó 1.025 filas, 14 columnas, cero valores faltantes y 723 duplicados exactos, como resume la Tabla 3. Se eliminaron duplicados para evitar que observaciones idénticas aparecieran simultáneamente en entrenamiento y prueba, lo que produciría fuga de información y métricas artificialmente optimistas.

Indicador	Valor
Filas originales	1.025
Columnas originales	14
Valores faltantes	0
Duplicados exactos	723
Filas luego de eliminar duplicados	302
Filas removidas	70,54 %

Cuadro 3: Resumen de limpieza del dataset.

3.3. Análisis exploratorio

En el dataset depurado, la clase se mantiene relativamente balanceada: 138 pacientes sin enfermedad y 164 con enfermedad. La Fig. 1 muestra esta distribución. La Tabla 4 resume diferencias descriptivas en variables continuas. Estas diferencias se interpretan como señales exploratorias, no como causalidad ni diagnóstico.




Figura 1: Distribución de la variable objetivo en el dataset depurado.

Variable	Prom. target 0	Prom. target 1	Interpretación breve
Edad	56,60	52,59	En promedio fue menor en pacientes con target=1 .
Presión reposo	134,40	129,25	Sugiere menor promedio en target=1 .
Colesterol	251,09	242,64	Diferencia moderada, menor en target=1 .
Frecuencia máxima	139,10	158,38	Mayor en target=1 .
Oldpeak	1,59	0,59	Menor en target=1 .

Cuadro 4: Comparación descriptiva de promedios por clase objetivo.

La Fig. 2 sugiere que **exang** ($r = -0,436$), **cp** ($r = 0,432$), **oldpeak** ($r = -0,429$), **thalach** ($r = 0,420$) y **ca** ($r = -0,409$) son las señales exploratorias más relevantes. Como varias son categóricas codificadas, la correlación debe entenderse solo como asociación numérica exploratoria; los boxplots de la Fig. 5 y los gráficos categóricos de la Fig. 6 quedan como evidencia complementaria en el anexo.




Figura 2: Matriz de correlación de variables del dataset depurado.

3.4. Clasificación

Se dividieron los datos en entrenamiento y prueba, usando 25 % para prueba con partición estratificada. Además, se aplicó validación cruzada estratificada de cinco pliegues. Para KNN se probaron $k = 3, 5, 7, 9, 11$ y el mejor promedio de F1 fue $k = 9$, por lo que se usó en la comparación final. Las métricas del split se presentan en la Tabla 5 y su comparación visual queda en la Fig. 7.

Modelo	Accuracy	Precision	Recall	F1-score
KNN k=9	0,803	0,771	0,902	0,832
Regresión logística	0,803	0,783	0,878	0,828
Árbol de decisión	0,789	0,778	0,854	0,814

Cuadro 5: Métricas de clasificación en conjunto de prueba.

Modelo	Acc. prom.	Acc. desv.	F1 prom.	F1 desv.
Regresión logística	0,831	0,038	0,851	0,034
KNN k=9	0,828	0,030	0,849	0,026
Árbol de decisión	0,785	0,054	0,801	0,057

Cuadro 6: Validación cruzada estratificada de cinco pliegues.

El mejor modelo en el split final por F1-score fue KNN con $F1 = 0,832$. Su matriz de confusión, mostrada en la Fig. 3, obtuvo 24 verdaderos negativos, 37 verdaderos positivos, 11 falsos positivos y 4 falsos negativos. La validación cruzada de la Tabla 6 muestra que regresión logística y KNN tienen desempeños muy cercanos, por lo que no se debe afirmar superioridad absoluta de un modelo.




Figura 3: Matriz de confusión del mejor modelo en el split final.

3.5. Clustering

Para clustering se usaron solo variables continuas escaladas: edad, presión arterial en reposo, colesterol, frecuencia cardíaca máxima y `oldpeak`. Se excluyó `target` y se evitaron variables categóricas codificadas como entrada directa. Según el codo y la silueta de la Fig. 4, el mejor valor fue $k = 2$, con silueta 0,240. Este valor permite una lectura exploratoria, pero indica separación limitada.




Figura 4: Método del codo y silueta para selección de clusters.

El cluster 0 agrupó 173 pacientes, con proporción de **target=1** de 0,717, edad media 49,60, frecuencia máxima media 161,47 y **oldpeak** medio 0,52. El cluster 1 agrupó 129 pacientes, con proporción de **target=1** de 0,310, edad media 60,89, frecuencia máxima media 133,61 y **oldpeak** medio 1,75. La proyección de la Fig. 8 y los perfiles de la Fig. 9 apoyan esta lectura exploratoria, aunque no representan clases clínicas cerradas.

4. Discusión y Reflexión

Los resultados responden la pregunta principal de forma exploratoria: las variables con mayor asociación numérica con **target** fueron angina inducida por ejercicio, tipo de dolor torácico, **oldpeak**, frecuencia cardíaca máxima y número de vasos coloreados. Como algunas variables son categóricas codificadas, estas asociaciones no deben leerse como relaciones lineales clínicas estrictas ni como causalidad.

La presencia de 723 duplicados exactos fue el punto metodológico más importante. Eliminarlos reduce el riesgo de fuga de información entre entrenamiento y prueba, porque una misma observación no debe aparecer en ambos subconjuntos. Sin embargo, pasar de 1.025 a 302 registros también disminuye el tamaño efectivo de muestra y puede afectar la estabilidad de las métricas. Por esta razón, se agregó validación cruzada y se mantienen las conclusiones como exploratorias.

La clasificación mostró rendimientos similares entre KNN y regresión logística. KNN tuvo el mejor F1 en el split final, pero la validación cruzada indica que la diferencia no es concluyente. El clustering aportó una segmentación útil para describir perfiles, aunque la silueta baja confirma separación limitada. En consecuencia, el análisis es adecuado como ejercicio de Inteligencia de Negocios y ciencia de datos aplicada, pero no como herramienta diagnóstica.

5. Conclusiones

Juan Muñoz concluye que CRISP-DM permitió ordenar el trabajo desde la pregunta de investigación hasta la evaluación. La evidencia más relevante fue la detección y eliminación de duplicados, decisión que fortaleció la calidad del análisis y evitó métricas infladas por repetición de registros.

Vicente Rivera concluye que las visualizaciones y tablas por **target** permitieron identificar patrones exploratorios. En particular, **exang**, **cp**, **oldpeak** y **thalach** destacaron como señales asociadas, aunque no deben interpretarse como causas clínicas.

Fernando Valdés concluye que los modelos simples sirven como línea base reproducible. KNN con $k = 9$ logró F1-score de 0,832 en prueba, pero la validación cruzada mostró desempeño muy cercano al de regresión logística, lo que exige prudencia al comparar modelos.

Como conclusión general, el dataset permite transformar registros clínicos en indicadores interpretables y perfiles exploratorios. Las limitaciones principales son el tamaño reducido después de eliminar duplicados, la naturaleza secundaria del dataset, la codificación numérica de variables categóricas y la separación limitada del clustering. El estudio no constituye diagnóstico médico.

Referencias

Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth.

- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., and Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. Technical report, SPSS Inc.
- Hosmer, D. W., Lemeshow, S., and Sturdivant, R. X. (2013). *Applied Logistic Regression*. Wiley, 3 edition.
- Hunter, J. D. (2007). Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95.
- James, G., Witten, D., Hastie, T., and Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer, 2 edition.
- Lévano, M. (2026a). CRISP-DM (CRoss-Industry Standard Process for Data Mining). Material de clase, INFO1184 Inteligencia de Negocios, semanas 1–3, Universidad Católica de Temuco. Archivo BI_003_S3.pdf.
- Lévano, M. (2026b). Datos conglomerados. Material de clase, INFO1184 Inteligencia de Negocios, semanas 3–4, Universidad Católica de Temuco. Archivo BI_03 2.pdf.
- Lévano, M. (2026c). Datos conglomerados: K-means. Material de clase, INFO1184 Inteligencia de Negocios, semana 6, Universidad Católica de Temuco. Archivo semana6 BI parte1.pdf.
- Lévano, M. (2026d). Regresión generalizada, estimación de parámetros y estimación del error. Material de clase, INFO1184 Inteligencia de Negocios, semana 8, Universidad Católica de Temuco. Archivo Semana_8.pdf.
- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, pages 281–297.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, E. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.
- Smith, J. (2026). Heart disease dataset. Kaggle. Dataset consultado para la Tarea 5.
- The pandas development team (2020). pandas-dev/pandas: Pandas. Zenodo.
- Waskom, M. L. (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60):3021.

A. Anexo: Evidencias del Desarrollo

A.1. Código fuente y reproducibilidad

El análisis fue implementado en Python mediante `main.py`. Las dependencias se declararon en `pyproject.toml` para ejecución con `uv`. La Tabla 7 detalla la estructura del proyecto y la Tabla 8 resume el diccionario de variables. El repositorio del grupo se encuentra en: <https://github.com/FernandoValdes01/INF01184>. La ruta del trabajo es TA/TA05/. El comando de ejecución usado fue `uv run python main.py`.

A.2. Estructura del proyecto

Ruta	Descripción
<code>heart.csv</code>	Dataset usado en el análisis.
<code>main.py</code>	Script reproducible de carga, limpieza, modelamiento y generación de salidas.
<code>pyproject.toml</code> / <code>uv.lock</code>	Dependencias y versiones resueltas con <code>uv</code> .
<code>figuras/</code>	Gráficos PDF generados automáticamente.
<code>salidas/</code>	Tablas CSV con resultados y evidencias.
<code>main.tex</code>	Informe académico en LaTeX.

Cuadro 7: Estructura de archivos del proyecto.

A.3. Diccionario de variables

Variable	Descripción	Tipo	Uso
<code>age</code>	Edad del paciente	Númerica	Exploración, clasificación y clustering
<code>sex</code>	Sexo biológico codificado	Binaria	Exploración y clasificación
<code>cp</code>	Tipo de dolor torácico	Cat. codificada	Exploración y clasificación
<code>trestbps</code>	Presión arterial en reposo	Númerica	Exploración, clasificación y clustering
<code>chol</code>	Colesterol sérico	Númerica	Exploración, clasificación y clustering
<code>fbs</code>	Glucosa en ayunas mayor a 120 mg/dl	Binaria	Exploración y clasificación
<code>restecg</code>	Electrocardiograma en reposo	Cat. codificada	Exploración y clasificación
<code>thalach</code>	Frecuencia cardíaca máxima	Númerica	Exploración, clasificación y clustering
<code>exang</code>	Angina inducida por ejercicio	Binaria	Exploración, clasificación y perfilado
<code>oldpeak</code>	Depresión ST inducida por ejercicio	Númerica	Exploración, clasificación y clustering
<code>slope</code>	Pendiente del segmento ST	Cat. codificada	Exploración y clasificación
<code>ca</code>	Vasos principales coloreados	Cat. codificada	Exploración y clasificación
<code>thal</code>	Resultado prueba thal	Cat. codificada	Exploración y clasificación
<code>target</code>	Presencia de enfermedad cardíaca	Objetivo	Clase y perfilado posterior

Cuadro 8: Diccionario resumido de variables.

A.4. Figuras complementarias

Las figuras complementarias amplían las evidencias citadas en el cuerpo principal: la Fig. 5 compara variables continuas por clase, la Fig. 6 resume variables categóricas codificadas, la Fig. 7 compara modelos, y las Figs. 8–9 apoyan el perfilado de clusters.




Figura 5: Comparación de variables numéricas según presencia de enfermedad cardíaca.




Figura 6: Distribución proporcional de variables categóricas codificadas por target.




Figura 7: Comparación visual de métricas de clasificación.




Figura 8: Proyección PCA de los clusters generados por K-Means.




Figura 9: Perfiles relativos de los clusters.

A.5. Archivos generados

La Tabla 9 lista las salidas principales que respaldan los resultados reportados, mientras que la Tabla 10 documenta la participación y secuencia de trabajo del grupo.

Archivo	Evidencia
00_diccionario_variables.csv	Diccionario de variables con tipo y uso.
03_duplicados_y_limpieza.csv	Resumen de limpieza y duplicados.
04b_comparacion_promedios_target.csv	Comparación de promedios por clase objetivo.
06_metricas_clasificacion.csv	Métricas del split final.
12_validacion_cruzada_modelos.csv	Validación cruzada estratificada.
13_validacion_knn_k.csv	Evaluación de valores de k para KNN.
14_importancia_permutacion_modelo.csv	Importancia por permutación del mejor modelo.

Cuadro 9: Principales archivos de evidencia generados por el script.

A.6. Bitácora de trabajo

Etap	Responsable principal	Actividad
Comprensión	Juan Muñoz	Revisión del enunciado, definición de preguntas y alcance del análisis de salud.
Datos	Vicente Rivera	Revisión de variables, faltantes, duplicados y consistencia del dataset.
Exploración	Grupo completo	Generación de tablas, boxplots, matriz de correlación y gráficos categóricos.
Modelamiento	Fernando Valdés	Clasificación, validación cruzada, búsqueda de k y matriz de confusión.
Clustering	Grupo completo	Selección de variables continuas, K-Means, PCA y perfilado de grupos.
Informe	Grupo completo	Redacción, revisión de resultados, referencias, anexos y conclusiones.

Cuadro 10: Bitácora resumida del desarrollo.