

Clasificación de Casos Familiares y Esporádicos de Neurofibromatosis Tipo 1 mediante Árbol de Decisión

Juan Muñoz, Vicente Rivera, Fernando Valdés

juan.munozveloso2023@alu.uct.cl, vriviera2023@alu.uct.cl, fvaldes2023@alu.uct.cl

Tarea 6, INFO1184, Semestre I-2026

Resumen

Este informe desarrolla la Tarea 6 de INFO1184 mediante un modelo de árbol de decisión aplicado al dataset *Neurofibromatosis Type 1: Clinical Symptoms of Familial and Sporadic Cases*, disponible en el repositorio UCI. El objetivo fue clasificar casos de NF1 como esporádicos o familiares a partir de síntomas clínicos, presencia de tumores y variables de edad, siguiendo CRISP-DM. Se usó el archivo Excel local `dataset-uci.xlsx`, con 296 registros y 20 columnas; el conjunto presenta 161 casos esporádicos, 135 familiares, 82 pacientes con tumores y valores faltantes solo en edades parentales o edad al primer diagnóstico. La preparación incluyó imputación por mediana y partición estratificada 75/25. El árbol final se entrenó con índice Gini, profundidad máxima 3, mínimo de 15 muestras por hoja y ponderación balanceada. En prueba obtuvo accuracy 0,473, precision 0,447, recall 0,618, F1 0,519 y AUC-ROC 0,521; la validación cruzada mostró F1 promedio 0,549. Las variables más influyentes fueron edad al primer diagnóstico, nódulos de Lisch, glioma óptico y edad de la madre. Los resultados son exploratorios y no constituyen diagnóstico médico.

Palabras clave: NF1, árbol de decisión, clasificación, CRISP-DM, Python, UCI.

1. Introducción

La neurofibromatosis tipo 1 (NF1) es una condición genética asociada a manifestaciones cutáneas, neurológicas, óseas y tumorales. En contextos clínicos y académicos, los registros de síntomas permiten estudiar patrones de presentación y construir modelos predictivos exploratorios. En este trabajo se analiza el dataset *Neurofibromatosis Type 1: Clinical Symptoms of Familial and Sporadic Cases*, incorporado al repositorio UCI en 2025 y vinculado al estudio de Sharafi et al. sobre predicción de casos familiares y esporádicos mediante aprendizaje automático (UCI Machine Learning Repository, 2025; Sharafi et al., 2025).

El objetivo general es aplicar el método árbol de decisión a un problema de clasificación binaria. La variable objetivo corresponde a **Case Type**: 0 para caso esporádico y 1 para caso familiar. La variable **Tumour Case** se mantiene como predictor y también se interpreta descriptivamente para discutir diferencias de prevalencia tumoral. La pregunta central es: ¿qué síntomas y variables clínicas ayudan a clasificar casos familiares y esporádicos de NF1?

El trabajo se implementó en Python mediante `pandas`, `numpy`, `scikit-learn`, `matplotlib` y `seaborn` (The pandas development team, 2020; Pedregosa et al., 2011; Hunter, 2007; Waskom, 2021). El proceso completo quedó automatizado en `nf1_analisis.py`, que carga datos, prepara variables, entrena el modelo, evalúa métricas y genera figuras reproducibles.

2. Fundamentos de Teoría

CRISP-DM organiza proyectos de minería de datos en seis fases: comprensión del negocio, comprensión de datos, preparación, modelado, evaluación e implementación. En el material de clases se destaca que el proceso es iterativo: los resultados de evaluación pueden exigir volver a preparación o modelado antes de comunicar conclusiones (Chapman et al., 2000; Lévano, 2026). En esta tarea se desarrollan las primeras cinco fases y la implementación se limita a documentar un flujo reproducible mediante informe, script y figuras.

La clasificación supervisada busca aprender una función que asigne una clase a cada observación a partir de variables predictoras. En este caso, la clase positiva corresponde a caso familiar de NF1. Un árbol de decisión divide los datos con reglas sucesivas del tipo “si-entonces”, por lo que resulta interpretable para comunicar hallazgos. Su riesgo principal es el sobreajuste: un árbol demasiado profundo puede memorizar el conjunto de entrenamiento y generalizar mal. Por esa razón se usa poda previa mediante profundidad máxima, mínimo de observaciones por hoja y validación cruzada (Breiman et al., 1984; Pedregosa et al., 2011).

El criterio Gini mide impureza de un nodo:

$$Gini = 1 - \sum_{i=1}^k p_i^2, \quad (1)$$

donde p_i es la proporción de la clase i en el nodo. Un valor 0 indica pureza completa. El desempeño se evalúa con accuracy, precision, recall, F1 y AUC-ROC, métricas conectadas con la estimación del error revisada en clases.

Accuracy resume aciertos globales; precision indica cuántas predicciones familiares fueron correctas; recall indica cuántos familiares reales fueron recuperados; F1 combina precision y recall.

3. Desarrollo del Trabajo

3.1. Comprensión del Negocio

Desde la perspectiva de inteligencia de negocios aplicada a salud, el problema consiste en transformar registros clínicos de pacientes con NF1 en evidencia interpretable sobre patrones de tipo de caso. La clasificación familiar/espórádica puede apoyar análisis epidemiológicos, priorización de revisión genética y comprensión de perfiles clínicos. Sin embargo, el alcance de esta tarea es académico: el modelo no reemplaza evaluación médica ni asesoramiento genético.

El criterio de éxito no se limita a obtener una métrica alta. Dado que el dataset es pequeño y los síntomas pueden solaparse entre grupos, se busca un flujo metodológico trazable, visualizaciones claras, una evaluación honesta y una interpretación prudente.

Etapas CRISP-DM	Aplicación en TA06
Comprensión del negocio	Clasificar casos de NF1 como familiares o esporádicos usando síntomas clínicos.
Comprensión de datos	Revisar dimensiones, variables, clases, faltantes, duplicados y prevalencia de síntomas.
Preparación de datos	Separar Case Type , eliminar ID, imputar edades y dividir train/test estratificado.
Modelado	Entrenar un árbol de decisión interpretable con poda previa y ponderación balanceada.
Evaluación	Reportar accuracy, precision, recall, F1, AUC-ROC, matriz de confusión y validación cruzada.
Comunicación	Documentar hallazgos, limitaciones y reproducibilidad en informe, figuras y README.

Tabla 1: Aplicación de CRISP-DM en el análisis NF1.

3.2. Comprensión de los Datos

El archivo usado fue `dataset-uci.xlsx`, ubicado en TA06/. La hoja **Dataset** contiene 296 registros y 20 columnas. La descripción UCI menciona 331 probandos, pero el Excel local disponible para la tarea contiene 296 filas efectivas; esta diferencia se mantiene documentada para reproducibilidad. La Tabla 2 resume la estructura principal.

Indicador	Valor
Registros en Excel local	296
Columnas totales	20
Variable objetivo	Case Type
Casos esporádicos	161
Casos familiares	135
Pacientes sin tumores	214
Pacientes con tumores	82
Duplicados exactos	0

Tabla 2: Resumen estructural del dataset NF1 usado.

La variable objetivo está moderadamente balanceada: 54,4% de casos esporádicos y 45,6% familiares. Esto permite usar una partición estratificada y métricas por clase, aunque sigue siendo necesario revisar precision, recall y F1 porque el objetivo positivo corresponde a la clase familiar. La distribución visual queda documentada en el anexo.

Las variables predictoras incluyen presencia de tumores, edad de la madre, edad del padre, edad al primer diagnóstico y síntomas binarios como manchas café con leche, pecas axilares, pecas inguinales, nódulos de Lisch, neurofibromas, glioma óptico, displasia esquelética, discapacidad de aprendizaje, hipertensión, astrocitoma, hamartoma, escoliosis y otros síntomas. Las tres variables de edad presentan valores faltantes: 35 en edad de la madre, 34 en edad del padre y 4 en edad al primer diagnóstico.

Variable	n válido	Media	Mediana	Min.	Max.
Edad de la madre	261	27,18	27,00	16,00	45,00
Edad del padre	262	31,88	31,00	19,00	62,00
Edad al primer diagnóstico	292	11,88	9,00	0,50	61,00

Tabla 3: Estadísticas descriptivas de variables de edad.

En prevalencia general, las manifestaciones más frecuentes fueron **Cafe au lait** (CLS) con 93,2%, pecas axilares

con 53,4 %, otros síntomas con 34,1 %, nódulos de Lisch con 28,0 %, presencia de tumores con 27,7 % y neurofibromas dermales con 27,7 %. La Fig. 1 compara prevalencias por tipo de caso.




Figura 1: Prevalencia de síntomas y tumores por tipo de caso NF1.

La diferencia descriptiva más visible fue que nódulos de Lisch aparecieron más en casos esporádicos (32,3 %) que familiares (23,0 %). En cambio, glioma óptico fue más frecuente en familiares (19,3 %) que esporádicos (13,0 %), displasia esquelética también fue mayor en familiares (22,2 % frente a 16,1 %) y la presencia de tumores subió de 25,5 % en esporádicos a 30,4 % en familiares. Estas diferencias son útiles para exploración, pero no implican causalidad clínica.

3.3. Preparación de los Datos

La preparación mantuvo el archivo original sin modificar. En el script se eliminó la columna identificadora ID, se separó **Case Type** como variable objetivo y se convirtieron las variables predictoras a formato numérico. Las variables binarias ya estaban codificadas como 0 para ausencia y 1 para presencia. Las edades se imputaron con la mediana, estrategia simple y robusta frente a asimetría moderada.

La división de datos usó 75 % para entrenamiento y 25 % para prueba, con estratificación por clase y semilla 1184. Además, se aplicó validación cruzada estratificada de cinco pliegues para estimar estabilidad y evitar depender solo de una partición. El procedimiento completo queda disponible en el script del anexo, evitando incorporar código fuente extenso en el cuerpo del informe.

3.4. Modelado

En este trabajo se usó **DecisionTreeClassifier** de **scikit-learn**. Para controlar sobreajuste se limitó la profundidad máxima a 3, se exigieron al menos 15 observaciones por hoja y se usó **class_weight="balanced"**, porque interesa que el modelo no ignore la clase familiar. El preprocesamiento y el modelo se integraron en un **Pipeline**.

La Fig. 2 presenta el árbol final. Sus reglas principales se concentran en edad al primer diagnóstico, nódulos de Lisch, glioma óptico y edad de la madre, lo que coincide con el ranking de importancia.




Figura 2: Árbol de decisión entrenado para clasificar casos familiares y esporádicos.

La Fig. 3 resume la importancia relativa de variables. Las cinco primeras fueron edad al primer diagnóstico (0,315), nódulos de Lisch (0,263), glioma óptico (0,251), edad de la madre (0,171) y edad del padre (0,000). Que varias variables queden en cero no significa irrelevancia clínica absoluta; significa que el árbol final podado no las usó para sus divisiones.




Figura 3: Importancia de variables en el árbol de decisión.

3.5. Evaluación

La evaluación se realizó en el conjunto de prueba y mediante validación cruzada. Las métricas usadas fueron accuracy, precision, recall, F1 y AUC-ROC. Para la clase positiva se consideró **Case Type = 1**, es decir, caso familiar.

Métrica en test	Valor
Accuracy	0,473
Precision clase familiar	0,447
Recall clase familiar	0,618
F1-score clase familiar	0,519
AUC-ROC	0,521

Tabla 4: Métricas del árbol de decisión en conjunto de prueba.

La matriz de confusión mostró 14 esporádicos correctamente identificados, 26 esporádicos clasificados como familiares, 21 familiares correctamente identificados y 13 familiares clasificados como esporádicos. El modelo privilegia recuperar casos familiares, pero al hacerlo aumenta falsos positivos. La curva ROC confirma una separación limitada entre clases: un AUC de 0,521 está apenas sobre el azar. Ambas visualizaciones quedan en el anexo.

Métrica en validación cruzada	Media	Desv. estándar
Accuracy	0,524	0,036
Precision	0,487	0,022
Recall	0,667	0,174
F1-score	0,549	0,078
AUC-ROC	0,528	0,041

Tabla 5: Validación cruzada estratificada de cinco pliegues.

La validación cruzada entrega un F1 promedio de 0,549 y recall promedio de 0,667 para la clase familiar, pero el AUC promedio sigue bajo. Esto sugiere que hay señales débiles o no lineales, y que un solo árbol puede ser insuficiente para capturar la relación entre síntomas y tipo de caso.

4. Discusión y Reflexión

El análisis permitió aplicar CRISP-DM de forma completa: se definió el objetivo de clasificación, se revisó la estructura del Excel, se imputaron valores faltantes, se entrenó un árbol de decisión y se evaluó con métricas de prueba y validación cruzada. El dataset local contiene 296 registros, menos que los 331 indicados en la descripción general de UCI, por lo que las conclusiones se restringen al archivo efectivamente analizado.

Los hallazgos principales son prudentes. Las diferencias descriptivas entre casos familiares y esporádicos existen, pero son pequeñas. La presencia de tumores fue algo mayor en familiares (30,4 %) que en esporádicos (25,5 %), mientras que nódulos de Lisch fueron más frecuentes en esporádicos. En el modelo, las variables usadas por el árbol fueron principalmente edad al primer diagnóstico, nódulos de Lisch, glioma óptico y edad de la madre. La variable **Tumour Case** no quedó entre las divisiones del árbol final, aunque descriptivamente sí muestra una diferencia leve entre grupos. El desempeño predictivo es limitado. El AUC cercano a 0,52 indica que el árbol apenas separa las clases mejor que una decisión aleatoria. Esto no invalida la tarea, pero obliga a interpretar el modelo como herramienta pedagógica e interpretativa. En salud, un resultado de este nivel no debe usarse para decisiones clínicas. Posibles mejoras incluyen validar con más datos, revisar codificación clínica, probar Random Forest, XGBoost o Gradient Boosting, ajustar umbrales de decisión y considerar interacciones no capturadas por un árbol pequeño.

5. Conclusiones

Juan Muñoz concluye que CRISP-DM ayudó a ordenar el problema desde la pregunta clínica hasta la evaluación, evitando saltar directamente al modelo. La principal evidencia fue que la preparación de datos y la revisión de clases condicionan toda lectura posterior.

Vicente Rivera concluye que las visualizaciones de distribución y prevalencia son claves para interpretar el dataset antes de modelar. En particular, las diferencias entre síntomas existen, pero no son suficientemente fuertes para sostener afirmaciones clínicas deterministas.

Fernando Valdés concluye que el árbol de decisión es valioso por su interpretabilidad, aunque sus métricas muestran límites claros. Para mejorar la capacidad predictiva se requerirían modelos de ensamble y validación externa.

Como conclusión general, el trabajo cumple el objetivo de investigar y aplicar árboles de decisión en un problema de clasificación con datos reales de NF1. Su aporte principal es una implementación reproducible, una evaluación honesta y una discusión metodológica alineada con la naturaleza exploratoria del dataset.

Referencias

- Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., and Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. Technical report, SPSS Inc.
- Hunter, J. D. (2007). Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95.
- Lévano, M. (2026). Material de clase info1184 inteligencia de negocios: Crisp-dm, modelamiento y evaluación. Material de clase, INFO1184 Inteligencia de Negocios, Universidad Católica de Temuco. Archivos BI_003_S3.pdf y Semana_8.pdf.

- OpenAI (2026). GPT: apoyo en revisión y refinamiento de redacción del informe. Asistente de inteligencia artificial utilizado para revisión ortográfica, consistencia formal y refinamiento editorial. El contenido, análisis e interpretación fueron validados por los autores del informe.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, E. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.
- Sharafi, P., Arslan, H., Ersoy Evans, S., Varan, A., and Ayter, S. (2025). A machine learning approach for predicting familial and sporadic disease cases based on clinical symptoms: introduction of a new dataset. *Turkish Bulletin of Hygiene and Experimental Biology*.
- The pandas development team (2020). pandas-dev/pandas: Pandas. Zenodo.
- UCI Machine Learning Repository (2025). Neurofibromatosis type 1: Clinical symptoms of familial and sporadic cases. Disponible en: <https://archive.ics.uci.edu/dataset/1162/neurofibromatosis+type+1+clinical+symptoms+of+familial+and+sporadic+cases>. Dataset consultado para la Tarea 6.
- Waskom, M. L. (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60):3021.

A. Anexo: Reproducibilidad y Bitácora

Declaración de elaboración y apoyo

El informe, el análisis de datos y la interpretación de resultados fueron elaborados por el grupo. Se utilizó GPT 5.5 como herramienta de apoyo editorial y de asistencia en programación para revisar consistencia formal, redacción y estructura reproducible (OpenAI, 2026). El contenido, los resultados y las conclusiones fueron revisados y validados por los autores del informe.

El análisis se reproduce ejecutando `nf1_analisis.py` desde la carpeta `TA06/`. El script genera automáticamente las seis figuras usadas en el informe dentro de `figuras/`. La Tabla 6 resume los archivos principales.




Figura 4: Distribución de clases de la variable objetivo Case Type.




Figura 5: Matriz de confusión y curva ROC del árbol de decisión.

Archivo	Descripción
dataset-uci.xlsx	Excel local con hoja Dataset .
nf1_analisis.py	Script reproducible de carga, preparación, modelado, evaluación y figuras.
figuras/arbol_decision.png	Visualización del árbol entrenado.
figuras/matriz_confusion.png	Matriz de confusión del conjunto de prueba.
figuras/curva_roc.png	Curva ROC y AUC del modelo.
figuras/importancia_features.png	Ranking de importancia de variables.
figuras/distribucion_clases.png	Balance de clases objetivo.
figuras/prevalencia_sintomas.png	Prevalencia de síntomas por tipo de caso.

Tabla 6: Estructura de archivos principales de TA06.

Etapas	Responsable principal	Actividad
Comprensión	Juan Muñoz	Revisión de enunciado, objetivo y enfoque CRISP-DM.
Datos	Vicente Rivera	Revisión de columnas, faltantes, clases y prevalencias.
Modelado	Fernando Valdés	Implementación del árbol de decisión, validación y métricas.
Visualización	Grupo completo	Generación y revisión de figuras explicativas.
Informe	Grupo completo	Redacción, discusión, conclusiones y revisión final.

Tabla 7: Bitácora resumida del trabajo.